

语义引导的水下带噪语音通信*

江昕越 刘佳惠 张榕鑫 朱逸 袁飞[†]

(厦门大学 水声通信与海洋信息技术教育部重点实验室 厦门 361005)

2024 年 6 月 27 日收到

2024 年 8 月 30 日定稿

摘要 针对狭窄带宽的多径水声信道和信源噪声干扰导致的退化语音,提出了一种语义引导的水下带噪语音通信系统,实现了噪声环境下高效鲁棒的语音通信。首先,通过引入语音去噪网络降低了信源噪声的影响。系统通过传输语音的语义信息,实现了语音信号的极限压缩。针对信道噪声对数据的损伤,使用语义纠错模块在接收端对退化的语义特征进行纠错,从而提高重建语音的可理解性。此外,结合多阶段训练策略的退化知情模型进一步增强所提方法在水声信道中的鲁棒性和泛化性。最后,在语音重建过程中使用多感受野-挤压激励融合模块以捕获语义特征中的全局语义信息,优化重建语音的可理解性。仿真实验结果表明,该方法在极低码率压缩的情况下,在复杂的噪声环境和不同的水声信道条件中,具有良好的重建性能。

关键词 水下语音通信, 语音语义通信, 低码率语音压缩, 带噪语音

PACS: 43.72, 43.30, 43.50

DOI: 10.12395/0371-0025.2024187

CSTR: 32049.14.11-2065.2024187

Semantic-guided underwater noisy speech communication

JIANG Xinyue LIU Jiahui ZHANG Rongxin ZHU Yi YUAN Fei[†]

(Key Laboratory of Underwater Acoustic Communication & Marine Information Technology,
Minister of Education, Xiamen University Xiamen 361005)

Received Jun. 27, 2024

Revised Aug. 30, 2024

Abstract To address degraded speech caused by narrow-bandwidth multipath underwater acoustic channels and source noise interference, this paper proposes a semantic-guided underwater noisy speech communication system, achieving efficient and robust speech communication in noisy environments. First, a speech-denoising network is introduced to reduce the impact of source noise. The system transmits the semantic information of speech, enabling extreme compression of the speech signal. In response to the damage caused by channel noise to the data, a semantic correction module is proposed to correct the degraded semantic features at the receiver, thereby improving the intelligibility of the reconstructed speech. Furthermore, the degradation-informed model, combined with a multi-stage training strategy, further enhances the robustness and generalization of the proposed method in underwater acoustic channels. Finally, the proposed multi-receptive-field squeeze-and-excitation fusion module is employed in the speech reconstruction process to capture global semantic information within the semantic features, optimizing the intelligibility of the reconstructed speech. Simulation results demonstrate that the proposed method delivers excellent reconstruction performance under very low bit rate compression, in complex noise environments, and across various channel conditions.

Keywords Underwater speech communication, Speech semantic communication, Low bit rate speech compression, Noisy speech

引言

水声信道因海洋噪声、多径效应和随机多普勒

效应的存在,成为最复杂的通信信道之一。水声信道的带宽十分狭窄,信号在传输过程中需经过压缩并以低比特率传输。浅海区域的多径时延扩展会导致信号衰落和码间串扰现象,使得接收到的数据出

* 国家自然科学基金项目 (62371404) 资助

[†] 通讯作者: 袁飞, yuanfei@xmu.edu.cn

现严重错误。此外, 信源噪声, 如潜水员呼吸时产生的呼吸噪声和气泡噪声^[1], 也严重影响了语音的清晰度, 低比特率编码技术对噪声敏感^[2], 这增加了语音编解码的难度^[3]。因此, 在平衡压缩有效性和传输鲁棒性的同时, 如何准确处理带噪的水下语音, 成为实现高效、鲁棒的水下语音通信亟待解决的问题。

传统水下语音通信算法^[4]以模块化设计, 将信源编码(如: MELP^[5])与信道编码(如: LDPC^[6])分离实现, 最低可达到 2.4 kbit/s 的编码速率。信源编码通过消除冗余信息实现语音压缩; 而信道编码则通过增加冗余来降低信道损伤。然而, 目前针对水下语音压缩与传输的研究仍较为有限, 随着编码技术的发展, 传统方法逐渐接近瓶颈^[7]。

基于深度学习的语音压缩方法进一步降低语音的编码速率, 大幅提高了重建语音的质量与可懂度。这些方法可大致分为两类: 基于端到端的方法和基于语音生成模型的方法。基于端到端的方法^[8-9]通过 VQVAE 的框架, 无先验信息, 直接训练编码-量化-解码网络, 数据驱动地学习高效的音频表示。基于生成模型的方法通常结合传统压缩方法, 从语音的特征表示映射至波形, 在重建高质量语音方面表现突出^[10]。其中, Polyak 等^[11]使用自监督离散表示实现了低比特率语音表示和重建。然而, 许多方法未考虑到实际应用场景中的信源噪声干扰。在这种情况下, 将去噪模型与编解码器级联是一种简单有效的方式: 先通过去噪模型抑制噪声, 再由编解码器进行压缩处理。此外, 一些研究通过联合压缩与增强, 不依赖级联去噪, 实现了低码率带噪语音的高效压缩^[12]。

基于深度学习的低码率语音压缩技术虽然提升了传输效率, 但在复杂通信环境中, 语义通信展现出更大的潜力。语义通信通过关注信息本身的含义而减少冗余, 大幅降低信道资源需求, 并能够在收发双方共有知识库的支持下重建丢失的信息, 具备强大的鲁棒性^[13]。在水声通信领域, 语义通信有望突破

传统通信限制。近年来的研究尝试通过挤压激励网络或文本相关语义特征实现语音语义传输^[14-15], 然而这些方法尚未充分考虑复杂的水声信道。此外, 现有的语音语义通信方法多数用于处理纯净语音, 在面对信源噪声时可能产生难以预测的结果。

总体来看, 许多方法主要专注于更低的比特率与更好的重建质量, 但未充分考虑噪声的影响。部分方法仅考虑信源或信道中的一种干扰, 鲜有方法能够兼顾信源噪声和信道噪声对语音的共同影响。大多数方法对误差敏感, 难以适应恶劣的水下环境。而那些考虑到信道干扰的语音语义通信方案往往忽略了信源噪声的干扰, 其在噪声环境中的性能还有待考察。

为了兼顾压缩有效性和传输鲁棒性, 同时降低信源噪声的干扰, 本文提出了语义引导的水下带噪语音通信 (Semantic-Guided Underwater Noisy Speech Communication, SUNSC) 系统。该系统采用级联语音去噪网络、声学模型与 VQVAE 框架, 实现语音的极限压缩, 并引入语义纠错模块和内嵌退化知情模型的多阶段训练策略, 提升了在水声信道下的鲁棒性。语义纠错模块通过将退化的语义特征映射到正确特征向量, 实现语义纠错。同时, 包含多感受野-挤压激励融合模块的语音重建网络, 提取全局语义信息, 优化了重建语音的可懂度。实验结果表明, 相较于现有的语音压缩方法, 本文所提方法能够有效应对信源噪声的干扰, 并且在不同的信道条件下都表现出良好的适应能力。

1 SUNSC 系统框架

SUNSC 的整体框架如图 1 所示, 包括发送端、水声通信和接收端。该系统旨在传输语音内容和音高相关的语义信息。在实际通信中, 语音信号不仅受到信源噪声的破坏, 还在经过水声信道时出现不同程度的劣化。SUNSC 的目标是在信源噪声干扰的情况下, 适应狭窄带宽、复杂多变的水声信道, 在接




图 1 SUNSC 的整体框架

收端重建出高可懂度的语音信号,实现语音语义信息高效、准确和鲁棒的传输。

1.1 发送端

SUNSC 的发送端由语音去噪网络 (SDN)、内容语义模块 (CSM)、音高语义模块 (PSM) 组成,用于从带噪语音中提取内容和音高语义特征。SUNSC 以带噪语音样本 $s_n \in \mathbb{R}^{B \times W}$ 为输入,其中, B 和 W 分别表示样本数量和长度。在发送端,去噪网络 $\text{SDN}(\cdot)$ 首先对 s_n 进行去噪,获得增强信号 $s_e \in \mathbb{R}^{B \times W}$ 。接着,内容语义模块 $C(\cdot)$ 和音高语义模块 $P(\cdot)$ 同步提取语音的内容和音高语义特征,并将其分别映射为比特流 x 在水声信道中传输。该过程可表示为

$$x = [x_\alpha, x_\beta] = [C(\text{SDN}(s_n)), P(\text{SDN}(s_n))], \quad (1)$$

其中, x_α 和 x_β 分别表示包含内容和音高语义信息的语义符号。

1.2 水声通信

水声信道有着严重的多径效应和海洋噪声,是一种复杂多变的信道^[16],因此水下语音通信系统需要具备十分优秀的抗信道干扰能力。待传输符号 $r(t) = [r_\alpha(t), r_\beta(t)] = [M(x_\alpha(t)), M(x_\beta(t))]$ 经过正交频分复用技术 (OFDM) 调制后,在水声信道中传输。其中, $r_\alpha(t)$ 和 $r_\beta(t)$ 分别表示内容与音高信息的待传输符号, $M(\cdot)$ 表示 OFDM 调制的过程。经过水声信道后的接收信号 $\hat{r}(t) = [\hat{r}_\alpha(t), \hat{r}_\beta(t)]$ 可表示为

$$\hat{r}(t) = h * r(t) + n, \quad (2)$$

其中, n 是加性高斯白噪声,满足 $n \sim \mathcal{N}(0, \sigma_n^2)$ 。 h 表

示水声信道的冲激响应,可表示为

$$h = \sum_{l=0}^{L_c} A_l(t) \delta(t - \tau_l(t)), \quad (3)$$

其中, t 代表时间, L_c 代表多径的数量, $A_l(t)$ 代表第 l 条径在 t 时刻的信号衰减值, $\tau_l(t)$ 表示第 l 条径在 t 时刻的延时。接收端对 $\hat{r}(t)$ 进行解调,恢复出比特流 $\hat{x} = [\hat{x}_\alpha, \hat{x}_\beta]$,用于语音重建。

1.3 接收端

接收端的 SUNSC 由语义纠错模块 (SCM) 和语音重建网络 (SRN) 组成。解调后的比特流 $\hat{x}_\alpha$ 与 $\hat{x}_\beta$ 通过 SCM 分别映射至正确的内容语义特征 $\hat{z}_\alpha$ 和音高语义特征 $\hat{z}_\beta$, 实现语义纠错。 $\hat{z}_\alpha$ 、 $\hat{z}_\beta$ 和接收端已知的音色信息 z_γ 共同组成多维度语义特征 y , 被送入 SRN, 从而生成高可懂度的重建语音 $\hat{s}$ 。整个过程可表示为

$$\hat{s} = G(y) = G(A(L(\mathbf{CB}_\alpha, \hat{x}_\alpha), A(L(\mathbf{CB}_\beta, \hat{x}_\beta)), z_\gamma)), \quad (4)$$

其中, $G(\cdot)$ 表示 SRN 的语音生成器, $L(\cdot)$ 和 $A(\cdot)$ 分别表示 SCM 中的特征查找器和语义纠错器, $\mathbf{CB}_\alpha$ 和 $\mathbf{CB}_\beta$ 分别表示内容语义码本和音高语义码本。

2 SUNSC 模型

SUNSC 将语音去噪网络 (SDN) 与语义引导的语音压缩部分进行级联。压缩部分包含语义提取模块 (SEM)、语义纠错模块 (SCM)、语音重建网络 (SRN)、退化知情模型 (DIM) 和共享知识库 (SKB), 分阶段进行训练, 如图 2 所示。阶段 1、阶段 2 以纯




图 2 SUNSC 模型流程图

净语音为输入 s_c , 阶段 3 以增强语音 s_e 作为输入, 下文统一记为 s 。

不同于文本和图像信息, 语音信号可以大致被分解为内容、音高和音色信息。传输的内容和音高语义特征由语义提取模块进行提取, 音色信息作为 SKB 的一部分不参与传输。DIM 生成退化数据集。SCM 对退化的内容和音高语义特征进行纠错。SRN 融合多维度语义特征, 提取全局语义特征, 完成语音重建。

2.1 语义提取模块

SUNSC 通过语义提取模块提取语音的内容和音高语义特征, 实现极限压缩。然而, 呼吸噪声和气泡噪声破坏了语音信号的原始频谱结构, 严重干扰了语音特征的提取, 如图 3 所示。因此, 本文使用高效的语音增强网络 MP-SENet^[17] 降低信源噪声的影响, 提高内容语义模块 (CSM) 和音高语义模块 (PSM) 对语音语义特征识别的准确性。CSM 和 PSM 结构相似, 均由编码器和量化器组成。




图3 信源噪声^[18]、纯净语音与未经过信道的信源噪声 (信噪比为 0 dB) 的带噪语音 (其中白色线条是利用基音跟踪算法 YAAPT^[19] 所提取的基音特征)

2.1.1 内容语义模块

语言的基本语义单位是单词, 由若干音素组成, 音素作为语音信号的最小单位, 反映了单词的发音。因此, 本文将音素序列视为语音的内容语义特征, 在 CSM 中采用预训练的声学模型 HuBert-Base^[20], 学习语音的内容语义特征。

CSM 由内容编码器 $E_\alpha(\cdot)$ 和内容量化器 $Q_\alpha(\cdot)$ 组成。HuBert 被作为 $E_\alpha(\cdot)$, 从语音样本 s 中提取包含了语音的频谱特征和上下文信息的连续音素表示 $z_\alpha \in \mathbb{R}^{B \times C_\alpha \times H}$:

$$z_\alpha = E_\alpha(s), \quad (5)$$

其中, C_α 和 H 分别表示 z_α 的通道数和大小。 $Q_\alpha(\cdot)$ 通过 K-means 聚类将音素表示量化至离散的音素序列, 生成 n 个大小为 C_α 的离散音素向量集合, 作为内容语义码本 CB_α 。 $Q(\cdot)$ 将 z_α 映射至其在 CB_α 中所对应的索引值, 并将其转换为比特流 x_α , 用于传输:

$$x_\alpha = Q_\alpha(z_\alpha). \quad (6)$$

CSM 依赖于掩码预测损失^[20] 学习音素序列。整体的掩码预测损失迫使模型预测被随机掩码的音素序列, 从而帮助模型理解语音的局部上下文和连续性, 进而学习语音中的音素序列, 即内容语义特征, 实现了对语音内容的极限压缩。

2.1.2 音高语义模块

除了内容语义特征, 音高也是语音的重要组成部分, 由基音决定, 反映了句子结构、信息焦点和重音等丰富的语义信息。因此, 本文利用 VQVAE 框架^[11] 作为音高语义模块 (PSM) 提取音高语义特征, 用于传输, 从而提高重建语音的自然度。

PSM 由音高编码器 $E_\beta(\cdot)$ 、音高量化器 $Q_\beta(\cdot)$ 和音高解码器 $D_\beta(\cdot)$ 组成, $D_\beta(\cdot)$ 仅在音高码本训练过程中被使用。通过 YAAPT^[19] 从 s 中提取得到的基音 p 作为 PSM 的输入。 p 首先被 $E_\beta(\cdot)$ 编码为音高语义特征 $z_\beta \in \mathbb{R}^{B \times C_\beta \times H'}$, 其中, C_β 和 H' 分别表示 z_β 的通道数和大小。随后, z_β 被 $Q_\beta(\cdot)$ 映射为其在音高码本中的索引值, 索引值被转换为比特流 x_β 。用于传输的 x_β 可表示为

$$x_\beta = Q_\beta(z_\beta) = Q_\beta(E_\beta(p)). \quad (7)$$

$E_\beta(\cdot)$ 由 4 个包含 1 个一维卷积和 1 个残差网络的模块组成, 以一个输出通道数为 C_β 的一维卷积层结束。 $Q_\beta(\cdot)$ 由一层瓶颈层构成。 $D_\beta(\cdot)$ 与 $E_\beta(\cdot)$ 的结构对称, 在训练中, 首先利用比特流 x_β 在码本中查找并恢复出音高语义特征 $\hat{z}_\beta \in \mathbb{R}^{B \times C_\beta \times H'}$, 并以重建的音高 $\hat{p}$ 作为输出:

$$\hat{p} = D_\beta(L(CB_\beta, x_\beta)). \quad (8)$$

在 VQVAE 的框架下, 音高特征在重建损失 $\mathcal{L}_{\text{recon}}$ 和量化损失 $\mathcal{L}_{\text{quant}}$ 共同约束下被提取, 形成包含 l 个 C_β 维向量的音高语义码本 CB_β 。整体损失函数 $\mathcal{L}_\beta$ 为

$$\mathcal{L}_\beta = \mathcal{L}_{\text{recon}} + \lambda_\beta \cdot \mathcal{L}_{\text{quant}} = \frac{1}{B} \sum_{i=1}^B (\hat{p}_i - p_i)^2 + \lambda_\beta \cdot \frac{1}{B \cdot C_\beta \cdot H'} \cdot \|z_\beta - \hat{z}_\beta\|_2^2, \quad (9)$$

其中, p_i 和 $\hat{p}_i$ 分别表示第 i 个样本的真实音高特征和重建音高特征。重建损失有助于保留音高的变化和语义信息。量化损失则约束了量化器的输入与码本查找的结果之间的平均均方误差, 确保编码的准确性和有效性。量化损失的权重 λ_β 设置为 0.2。

2.2 语义纠错模块

为了提取、恢复正确的语义特征, 完成语义纠错

任务,本文提出了语义纠错模块(SCM)。虽然增强语音一定程度上能够去除信源噪声并提高编码器识别语义特征的准确性,但噪声仍然存在,并可能导致伪影,如图4所示。因此,编码后的语义特征难免受到损伤。这些损伤的语义符号在恶劣的水声信道中传输,进一步损坏接收端接收到的语义符号。SCM分别对损伤的内容和音高比特流进行处理,学习信源噪声和水声信道对语义特征的影响,从退化的语义特征中还原出正确的语义特征作为输出,为语音重建提供可靠输入。

SCM的网络结构如图5所示。首先,包含内容语义的比特流 $\hat{x}_\alpha$ 被转换为十进制索引值后,通过内容语义码本 CB_α 提取得到内容语义特征 $\hat{z}_{na}$ 。该过程可表示为

$$\hat{z}_{na} = L(CB_\alpha, \hat{x}_\alpha), \quad (10)$$

其中, $L(\cdot)$ 表示特征查找器。值得注意的是,经过退化知情模型或水声信道的比特流中所包含的信息是损伤的,因此从码本中提取的语义特征也是损伤的。随后,语义纠错器 $A(\cdot)$ 对 $\hat{z}_{na}$ 进行纠错,得到恢复的内容语义特征 $\hat{z}_\alpha$,即

$$\hat{z}_\alpha = A(\hat{z}_{na}), \quad (11)$$

其中, $A(\cdot)$ 通过将不同卷积块输出的特征进行拼接,并采用跳跃连接的方式,将不同的卷积块连接起来,以学习更多层次的特征。类似地,恢复的音高语义特征 $\hat{z}_\beta$ 可以通过 $L(\cdot)$ 和 $A(\cdot)$ 得到:

$$\hat{z}_\beta = A(\hat{z}_{n\beta}) = A(L(CB_\beta, \hat{x}_\beta)), \quad (12)$$

其中, $\hat{x}_\beta$ 表示包含音高语义信息的比特流, $\hat{z}_{n\beta}$ 表示

损伤的音高语义特征。最后,所修复的语义特征 $\hat{z}_\alpha$ 和 $\hat{z}_\beta$ 被共同送入语音重建网络进行语音重建。

2.3 语音重建网络

为了进一步修复和纠正因信源噪声和水声信道损伤的语义特征,实现高可懂度的语音重建,本文提出了一种包含多感受野-挤压激励融合模块(Multi-Receptive Field and Squeeze-Excitation Fusion, MRF-SE)的语音重建网络SRN。MRF-SE能够融合内容、音高和音色信息的语义特征,同时进一步获取全局语义特征,优化重建语音的可懂度。MRF-SE中的卷积块具有不同的卷积核大小和扩张率,从而形成了多样化的感受野。此外,挤压-激励的操作通过捕捉不同卷积通道之间的相互依赖关系,从而获得不同卷积通道特征的语义重要性权重。因此, MRF-SE能够捕捉全局语义特征,学习语义特征与原始音频特征之间的映射关系,最终生成与原始音频高度一致的语音。受文献[21]启发,本文引入了多尺度鉴别器(MSD)和多周期鉴别器(MPD)从不同角度处理语音。

生成器网络结构如图6所示,以SCM所恢复语义特征 $\hat{z}_\alpha$ 与 $\hat{z}_\beta$ 以及共享知识库中的音色信息 z_γ 共同组成的综合特征 y 作为输入。 z_γ 是SRN从语音中抽象出的一组与内容和音高无关的向量,用于提升语音重建的自然度,因此作为SKB的一部分, z_γ 并不参与传输。 y 表示为

$$y = [\hat{z}_\alpha, \hat{z}_\beta, z_\gamma], y \in \mathbb{R}^{B \times (3 \times C) \times H}, \quad (13)$$

其中, z_γ 与SRN一同被训练。最终,生成器生成重




图4 纯净语音、带噪语音、增强语音及其中的噪声和伪影




图5 语义纠错模块的网络结构




图6 生成器网络结构

建语音, 即

$$\hat{s} = G(y), \quad (14)$$

其中, $G(\cdot)$ 表示生成器。鉴别器组中 MPD 在语音的不相交样本上进行计算, 而 MSD 则工作在平滑的连续语音样本上。两者与 MRF-SE 协同工作, 识别全局语义特征, 辅助生成器重建语音。

SRN 的损失函数与文献 [21] 相同。为了便于描述, 本文将鉴别器组看作一个整体, 记作 D 。整体的生成损失 $\mathcal{L}_G$ 由生成对抗损失 $\mathcal{L}_{adv}(G; D)$, 梅尔频谱损失 $\mathcal{L}_{Mel}$ 和特征匹配损失 $\mathcal{L}_{fm}$ 组成。生成损失可表示为

$$\mathcal{L}_G = \mathcal{L}_{adv}(G; D) + \lambda \mathcal{L}_{Mel} + \mu \mathcal{L}_{fm}, \quad (15)$$

其中, 本文设置 $\lambda = 45$, $\mu = 2$ 。鉴别器损失为

$$\mathcal{L}_{adv}(D; G) = \sum_j^M E_{(s, \hat{s})} \left((D_j(\hat{s}) - 1)^2 + D_j(s)^2 \right). \quad (16)$$

2.4 内嵌退化知情模型的多阶段训练策略

为了提高所提方法的泛化性和鲁棒性, 使 SUNSC 能够在信源噪声干扰的情况下也能适应复杂多变的水声信道, 本文提出了退化知情模型 (DIM), 并结合信源信道联合编码, 引入了多阶段训练策略, 如图 4 所示。DIM 模拟了信道对数据造成的损伤, 生成退化数据集, 而多阶段训练策略则迫使模型逐步学习退化语义特征到正确语音之间的映射关系。整体训练流程由表 1 给出。

为了捕捉语义特征与音频特征之间的关系, 生成可懂度良好的语音, 首先忽略信源噪声和水声信道的影响, 使用来自纯净数据集的无损语义特征进行阶段 1 和阶段 2 的训练。阶段 1 以 VQVAE 为框架, 训练得到音高编码器 $E_\beta(\cdot)$ 、量化器 $Q_\beta(\cdot)$ 和音高语义码本 CB_β 。阶段 2 将预训练声学模型 HuBert 和 K-means 分别作为内容语义编码器 $E_\alpha(\cdot)$ 和量化器 $Q_\alpha(\cdot)$, 在阶段 1 的基础上, 训练内容语义码本 CB_α 、音色信息 z_y 和语音重建网络 $G(\cdot)$ 、 $D(\cdot)$, 得到初步模型 Model-A。为了让 SUNSC 更好地理解信道损伤并

提升其泛化性和鲁棒性, 在阶段 3 中结合 DIM, 以增强后的语音作为输入进行训练。值得注意的是, 语音去噪网络在此之前已经独立完成了训练。DIM 示意图由图 7 给出, 通过动态随机误码信道使编码后的比特流中某些位置随机出错, 以此反映水声信道的动态性和复杂性, 避免对单一信道的依赖。如表 1 所示, 阶段 3 在 Model-A 基础上仅训练 SCM $A(\cdot)$, 并冻结其他所有模块参数。最后微调得到 Model-B。表 2 则给出了实际语音传输的推理流程。

本文通过多阶段训练策略中使用退化知情模型, 提升了 SUNSC 的泛化性和鲁棒性, 从而能够更好地适应复杂多变的水声信道。

3 性能分析

3.1 实验设置与评价指标

3.1.1 实验数据

本文选用语音合成领域常用的 LJSpeech^[22] 作为纯净语音数据集。LJSpeech 包含 13100 条纯净女声的语音。每条语音时长在 1~10 s 不等, 总时长约 24 h, 以 22.05 kHz 进行采样。训练集、验证集和测试集以 9:0.5:0.5 的比例被划分。噪声数据集来源于泳池中采集的潜水员呼吸噪声和气泡噪声^[18], 总时长约 15 min, 采样率调整至 16 kHz, 以 6:2:2 的比例划分为训练集、验证集和测试集。本文随机截取训练集、验证集和测试集中的噪声片段, 以 0~18 dB 的随机信噪比添加在对应集合的纯净数据集上, 生成带噪语音数据集。其中, 训练集和验证集的信噪比为随机选取, 而测试集的信噪比则为 [0, 3, 6, 9, 12, 15, 18] dB 的固定值。

3.1.2 实验设置

本文将所提方法与现有的语音压缩编码方法进行比较。经典的传统方法 MELP + 1/2LDPC 使用 MELP^[5] 进行信源编码, LDPC^[6] 进行信道编码。基于深度学习的方法包括 HuBert^[11]、EnCodec^[8]、SEStream^[12] 和 DeepSC-S^[15]。其中, DeepSC-S 是在 SNR_c 为 8 dB 的高斯信道下训练的语音语义通信方

表 1 SUNSC 多阶段训练流程

算法1 SUNSC多阶段训练流程

输入: 纯净语音 s_c , 增强语音 s_e , 退化知情模型 $\text{DIM}(\cdot)$, 预训练的 $E_a(\cdot)$ 和 $Q_a(\cdot)$

输出: 训练完成的 $E_\beta(\cdot)$, $Q_\beta(\cdot)$, $G(\cdot)$, CB_α , CB_β , z_γ

01	$CB_\alpha, CB_\beta, z_\gamma$ 初始化	// CB_α : 内容语义码本, CB_β : 音高语义码本 // z_γ : 音色信息
02	阶段1训练	
03	while Stop criterion is not meet do:	
04	$s = s_c$	
05	从 s 中提取基音 p	
06	根据式(7), $Q_\beta(E_\beta(p)) \rightarrow x_\beta$	//音高特征编码量化
07	根据式(8), $D_\beta(L(CB_\beta, x_\beta)) \rightarrow \hat{p}$	//特征查找, 解码
08	根据式(9)计算 $\mathcal{L}_\beta$, 更新 $E_\beta(\cdot)$, $Q_\beta(\cdot)$, $D_\beta(\cdot)$, CB_β	
09	end while , 冻结 $E_\beta(\cdot)$, $Q_\beta(\cdot)$, CB_β	
10	阶段2训练	
11	while Stop criterion is not meet do:	
12	重复4~6步	
13	根据式(5)(6), $Q_\alpha(E_\alpha(s)) \rightarrow x_\alpha$	//内容特征编码量化
14	$L(CB_\alpha, x_\alpha) \rightarrow \hat{z}_\alpha$, $L(CB_\beta, x_\beta) \rightarrow \hat{z}_\beta$	//特征查找
15	根据式(13), $\text{Concat}(\hat{z}_\alpha, \hat{z}_\beta, z_\gamma) \rightarrow y$	//特征拼接
16	根据式(14), $G(y) \rightarrow \hat{s}$	//语音重建
17	根据式(15)(16)计算 $\mathcal{L}_G$, $\mathcal{L}_{\text{adv}}$, 更新 $G(\cdot)$, $D(\cdot)$, CB_α , z_γ	
18	end while , 冻结 $G(\cdot)$, $D(\cdot)$, CB_α , z_γ	
19	阶段3训练	
20	while Stop criterion is not meet do:	
21	$s = s_e$, 重复5, 6, 13步	//阶段3输入为增强语音, 内 //容、音高特征编码量化
22	$\text{DIM}(x_\alpha) \rightarrow \hat{x}_\alpha$, $\text{DIM}(x_\beta) \rightarrow \hat{x}_\beta$	//引入退化知情模型, 生成退 //化数据
23	根据式(10)(11)(12), 得到 $\hat{z}_\alpha$, $\hat{z}_\beta$	//特征查找, 语义纠错
24	重复15~16步	
25	根据式(15)计算 $\mathcal{L}_G$, 更新语义纠错模块 $A(\cdot)$ 参数	
27	end while , 取消冻结 $G(\cdot)$, $D(\cdot)$, CB_α , z_γ	
28	微调阶段	
29	while Stop criterion is not meet do:	
30	重复21~24步	
31	根据式(15)(16)计算 $\mathcal{L}_G$, $\mathcal{L}_{\text{adv}}$, 更新 $G(\cdot)$, $D(\cdot)$, $A(\cdot)$, CB_α , z_γ	
32	end while	
33	训练完成	




图 7 退化知情模型与多阶段训练策略

表 2 推理阶段整体流程

算法2 SUNSC推理流程			
输入: 带噪语音 s_n , 水声信道冲激响应 h 、高斯白噪声 n			
输出: 重建语音 $\hat{s}$			
01	发送端:		
02	$SDN(s_n) \rightarrow s_e$	// 语音去噪	
03	从 s_e 中提取基音 p		
04	$Q_\alpha(E_\alpha(s_e)) \rightarrow x_\alpha, Q_\beta(E_\beta(p)) \rightarrow x_\beta$	// 编码量化	
05	$M(x_\alpha) \rightarrow r_\alpha, M(x_\beta) \rightarrow r_\beta$	// OFDM调制	
06	水声通信:		
07	根据式(2), r_α 、 r_β 在水声信道中传输, 接收并解调得到 $\hat{r}_\alpha$ 、 $\hat{r}_\beta$		
08	接收端:		
09	根据式(10)(11)(12), 得到 $\hat{z}_\alpha, \hat{z}_\beta$	//特征查找, 语义纠错	
10	根据式(13), $\text{Concat}(\hat{z}_\alpha, \hat{z}_\beta, z_\gamma) \rightarrow y$	//特征拼接	
11	根据式(14), $G(y) \rightarrow \hat{s}$	//语音重建	
12	Return $\hat{s}$		

法。SEStream 考虑到信源噪声, 是一种联合压缩和增强的算法。因此, SEStream 遵循文献 [12] 的设置, 在带噪语音数据集上训练至收敛。而未考虑到信源噪声的方法在纯净数据集上训练至收敛, 并以增强后的测试集语音进行测试。所有模型均在 NVIDIA GeForce RTX 3090Ti GPU, 64G RAM, 和 Intel(R) Core(TM) i9-12900K CPU 上进行训练和测试。训练中批次大小为 16, 学习率为 2×10^{-4} 。语音去噪网络被预先训练至 100 个 epoch。SUNSC 的训练分阶段进行: 阶段 1 的音高语义模块训练至 500 个 epoch 后被冻结, 阶段 2 从第 1 个 epoch 开始重新训练至 200 个 epoch, 阶段 3 在此基础上训练至 250 个 epoch, 最后, 微调至 340 个 epoch, 完成整个训练过程。

本文采用正交相移键控 (QPSK) 进行星座映射, OFDM 进行调制, 利用 Chirp 信号进行同步, 解调均衡器使用频域最小均方误差。对于编码结果为模拟值的 DeepSC-S 则采用伪模拟方式^[23]进行星座映射, 将编码结果的幅值映射至待传输符号的实部和虚部, 使用数字硬件进行发送。OFDM 的参数设置如表 3 所示。

3.1.3 评价指标

语音语义通信系统的性能关注重建语音的内容与质量, 同时语义特征的准确性也与任务相关。在水下语音通信中, 任务的核心是确保接收端能够重建出可懂度良好的语音, 准确传递信息, 因此允许语音质量存在一定失真。短时客观可懂度 (STOI) 是衡量语音可理解程度的重要指标^[24], 它将语音的可理解程度量化至 0~1, 取值为 1 代表语音被充分理解。另外, 本文还使用倒谱距离 (CD)^[25]来重建语音与原

表 3 OFDM 参数设置

参数	数值	参数	数值
带宽	6.4 kHz	导频长度	40 ms
符号时间	40 ms	激活子载波数量	128
保护间隔	10 ms	每帧符号数	8
星座映射	QPSK	比特率	4.7 kbit/s
循环前缀长度	10 ms		

始纯净语音之间的相似性与失真程度。CD 是与语音的主观质量密切相关的客观指标。CD 越低, 表明重建语音与原始纯净语音越相似。此外, 本文还给出了重建语音通过语音识别模型 SenseVoice^[26]转换为文本后的词错率 (WER) 和双语评估替代 (BLEU) 结果。WER 用于衡量文本差异, 而 BLEU 近年来被用于文本语义通信系统, 评估句子之间的语义相似性。值得注意的是, WER 和 BLEU 作为文本评价指标, 注重精确的文本匹配, 而 STOI 和 CD 关注的是语音的清晰度和可懂度。

3.2 实验结果与分析

本节从有效性和鲁棒性两个方面验证 SUNSC 的性能。为便于描述, 将信道噪声的信噪比记作 SNR_c , 信源噪声的信噪比记作 SNR_s 。

3.2.1 有效性验证

通信的有效性一方面体现在编码速率, 另一方面体现在重建语音的可理解程度和准确性。由于 DeepSC-S 的编码结果为模拟数, 其余方法为比特流, 为了统一对比, 使用符号率 (SR) 来评估编码速率。时长为 T 的语音的编码结果包含了 N 个比特或 N 个模拟数, 经过星座映射后得到的待传输符号数为

$N_s = N/2$, 则符号率 SR 可表示为

$$\text{SR} = \frac{N_s}{T}, \tag{17}$$

SR 表示每秒符号数 (symbols per second, sps), 即编码 1 s 的语音所需的符号数。较低的符号率意味着编码后的数据量较少, 传输时间也相应更少。表 4 为 $\text{SNR}_s = 0 \text{ dB}$ 且无信道干扰时, 不同方案的有效性比较。本文提出的 SUNSC 方案具有最低的符号率, 即编码后的数据量最少。DeepSC-S 的重建语音取得了最优的性能, 这是由于该方法直接对波形进行编码, 符号率较高, 丢失的信息较少。而 SUNSC 在最低符号率的情况下, 重建语音仍能达到中上水平。虽然所有方法文本评价指标的结果不是十分理想, 这与压缩本身带来的信息丢失、语音识别模型本身性能以及文本评价指标与语音感知之间存在差异都有关系, 但在同一语音转文本的模型下, SUNSC 仍然取得了良好的结果。因此, SUNSC 在有效性方面不逊于现有的语音编码方法。

图 8 为部分重建语音的梅尔谱。与原始纯净语音对比时, EnCodec 与 MELP 的细节谱线较为模糊, HuBert 的音高特征则出现轻微失真, DeepSC-S 的谱线清晰, 几乎无失真。而经过联合压缩与增强的 SEStream 的整体谱线和音高特征与原始语音较为相似, 这说明该方法在应对信源噪声方面具有良好的效果。本文提出的 SUNSC 谱线清晰, 虽然音高特征出现轻微失真, 但整体趋势仍与原始语音相似, 因此不影响其可理解性。

3.2.2 鲁棒性验证

水声信道的多径效应和噪声干扰十分严重, 导致接收端接收的信号出现严重的误码现象。本节基于表 3 的设置进行仿真实验, 测试不同编码方案在同类型水声信道中的性能。使用式 (2) 模拟信道对输入信号的作用, 其中信道冲激响应 h 来自多场景验证数据集^[27] 的实测水声信道数据。该数据集包含了在挪威-大陆架 (NCS)、挪威-奥斯陆菲尤尔 (NOF) 和中国-万鲁水库 (CWR) 三个地点的上万条原始信道冲激响应测试数据, 其信道探测结果如图 9 所示。先前的工作^[16] 中, 信道模型根据典型水声信道实测数据的误码模版设置, 以动态调节信道状况。本文则进一步采用公开的实测水声信道数据集用于鲁棒性测试。相同的通信设置下, 比较不同方法在相同信道干扰条件下的重建语音可懂度和失真程度。值得注意的是, SUNSC 在多阶段训练结束后, 无需针对不同地点重新训练。

SNR_s 为 0 dB 的带噪语音在上述的水声信道传输得到的重建质量比较结果如图 10 所示。其中, 水声信道中加入了不同 SNR_c 的高斯噪声。相同的带噪语音在不同信道中传输时, 随着信道条件的恶化, SNR_c 的降低, 重建质量也有不同程度的下降。在 CWR 的信道条件下, 传统方法 MELP + 1/2LDPC 的重建质量相对稳定, 得益于其信道编码的有效性。尽管如此, 该方法重建语音的可理解程度仍低于基于深度学习的方法, 这是传统有损压缩方法所面临的瓶颈。在 NCS 和 NOF 信道中, LDPC 的保护效果

表 4 信源噪声 $\text{SNR}_s = 0 \text{ dB}$ 且无信道干扰下的重建性能对比

	原始语音	HuBert	EnCodec	MELP	SEStream	DeepSC-S	SUNSC
SR (ksp/s)↓	—	0.208	0.750	1.200	1.500	327.680	0.208
STOI↑	—	0.790	0.752	0.443	0.708	0.920	0.790
CD↓	—	5.033	8.153	6.207	4.939	4.107	5.007
WER↓	5.00%	30.34%	31.80%	90.48%	30.15%	13.54%	28.83%
BLEU↑	0.905	0.708	0.693	0.565	0.724	0.869	0.724




图 8 信源噪声 $\text{SNR}_s = 0 \text{ dB}$ 且无信道噪声干扰下重建语音的梅尔谱 (白色线条表示音高特征)





图9 多场景验证数据集的信道探测示例 (a) NCS ; (b) NOF ; (c) CWR

图10 信源噪声 $\text{SNR}_s = 0 \text{ dB}$ 时在不同 SNR_c 水平不同类型信道中的重建性能对比

减弱,甚至出现了悬崖效应。这说明 MELP + 1/2LDPC 在不同的水声信道条件下的泛化能力有限。在有效性验证中,具有最佳重建性能的 DeepSC-S 在水声信

道中的重建质量显著下降,这是因为模拟通信易受信道扰动的影响,导致该方法整体鲁棒性表现不佳。与 SUNSC 在有效性验证中表现接近的 HuBert

和 SEStream 在水声信道中重建质量也显著下降。当 SNR_s 为 0 dB, SUNSC 在三类信道中 STOI 和 CD 的整体曲线均优于其他方法, 展现出卓越的重建质量。这表明 SUNSC 在相同信道干扰下, 能够高效、鲁棒地完成水下语音语义通信。文本评价指标的变化趋势与 STOI、CD 的变化趋势相似, SUNSC 在文本评价指标上也展现出最优的鲁棒性。

图 11 进一步展示了不同方法在 SNR_s 为 0 dB, SNR_c 为 12 dB 的 NCS 信道条件下部分重建语音的梅尔谱图。可以观察到, DeepSC-S 的谱图中充斥着噪声, 黄色谱线和音高特征均失真严重。EnCodec、MELP + 1/2LDPC 和 SEStream 整体噪声水平较高, 音高特征失真严重, 黄色的谱线模糊, 几乎失效。相比之下, HuBert 的噪声较少, 谱线也更清晰, 但与原始纯净语音相比, HuBert 的谱线和音高特征依然存在明显失真。而 SUNSC 噪声水平更低, 谱线更清晰, 且其谱线与音高特征与原始纯净语音相似, 这说明 SUNSC 在信源噪声和信道噪声的双重干扰下, 在保真度和降噪方面表现出色。本节仿真实验验证了 SUNSC 在信源噪声的干扰下及恶劣的水声信道中仍然具有优秀的鲁棒性, 并且在多种水声信道场景中的泛化性良好。

3.2.3 误码性能对比

为了更直观地展示 SUNSC 的鲁棒性, 对比 NCS 信道下各方法的接收数据误码率, 如表 5 所示。由于 DeepSC-S 的数据量较大, 其编码结果为模拟值, 并且在上述鲁棒性验证中表现不佳, 因此未将其纳入比较。各方法在相同的通信设置和相同的信道条件下, 接收数据误码率相近, 且处于同一水平。结合

前述的鲁棒性实验结果可以得出, 在相同程度的信道干扰下, SUNSC 能够有效抵抗干扰, 在接收端成功重建出高可懂度的语音, 实现了高效、鲁棒的水下语音语义通信, 这正是 SUNSC 的优势所在。

3.2.4 消融实验

为验证各模块的有效性, 逐步删除 SUNSC 的各个模块, 在冻结 CSM 和 PSM 的情况下进行重新训练, 并在 $\text{SNR}_s = 0 \text{ dB}$, $\text{SNR}_c \in [0 \text{ dB}, 12 \text{ dB}, 24 \text{ dB}]$ 的 NCS 信道下进行测试。所有参数设置和训练步骤与 SUNSC 保持一致。具体而言, w/o DIM 在纯净数据集上训练至收敛, 测试时以增强语音作为输入。w/o SDN 是联合压缩与增强的模型, 训练步骤与 SUNSC 一致, 但阶段 3 使用带噪语音为输入进行训练和测试。w/BSRNN 是将 SUNSC 中的语音去噪网络替换为 BSRNN^[28]。表 6 为消融实验的结果。

与 SUNSC 相比, w/o SCM 的整体重建性能有所下降, 这是由于其难以从错误的语义特征中恢复出正确的特征, 导致在干扰下重建语音的可懂度迅速降低。w/o MRF-SE 由于缺乏提取全局语义特征的能力, 因此, 其重建质量也低于 SUNSC。另一方面, w/o DIM 未考虑噪声扰动, 在高信噪比区域表现良好, 但随着噪声干扰的增大, 其重建质量快速下降, 凸显了 DIM 在面对恶劣水声信道时的有效性。以联合压缩与增强方式训练的 w/o SDN 在带噪数据集上的整体重建性能不如 SUNSC, 说明 SUNSC 中语音去噪网络与语音压缩算法的级联更为有效。最后, 尽管更换了语音去噪网络, w/BSRNN 的重建性能仍与 SUNSC 相当, 表明语音去噪网络在系统中的贡献有限, 非主要影响因素。




图 11 $\text{SNR}_s = 0 \text{ dB}$ 且 NCS 中 $\text{SNR}_c = 12 \text{ dB}$ 时部分重建语音的梅尔谱图

表 5 不同方法在 $\text{SNR}_s = 0 \text{ dB}$, $\text{SNR}_c \in [0 \text{ dB}, 12 \text{ dB}, 24 \text{ dB}]$ 的 NCS 信道下的误码率

SNR_c	HuBert	EnCodec	MELP + 1/2LDPC	SESteam	SUNSC
0 dB	2.289×10^{-1}	2.277×10^{-1}	2.252×10^{-1}	2.294×10^{-1}	2.301×10^{-1}
12 dB	5.659×10^{-2}	5.612×10^{-2}	5.624×10^{-2}	5.647×10^{-2}	5.740×10^{-2}
24 dB	5.111×10^{-3}	4.907×10^{-3}	5.081×10^{-3}	4.936×10^{-3}	5.024×10^{-3}

表 6 消融实验结果 (SNR_s = 0 dB, SNR_c ∈ [0 dB, 12 dB, 24 dB] 的 NCS 信道)

模型	STOI↑			CD↓		
	0 dB	12 dB	24 dB	0 dB	12 dB	24 dB
w/o SCM	0.441	0.732	0.780	7.723	5.571	5.262
w/o MRF-SE	0.442	0.732	0.776	7.529	5.376	5.120
w/o DIM	0.370	0.659	0.790	8.125	6.120	5.020
w/o SDN	0.368	0.647	0.691	7.836	5.920	5.532
w/ BSRNN	0.442	0.695	0.717	7.635	5.719	5.469
SUNSC	0.444	0.743	0.786	7.522	5.329	5.028

表 7 复杂度对比

		MELP + 1/2LDPC	HuBert	EnCodec	SESteam	DeepSC-S	SUNSC(Ours)
平均处理时间 (s)		7.92	0.43	0.84	0.02	0.41	0.52
FLOPs	发送端	—	7.87×10^{11}	8.98×10^{10}	3.80×10^7	9.25×10^{10}	7.87×10^{11}
	接收端	—	8.46×10^9	5.48×10^9	3.88×10^7	4.71×10^9	1.84×10^{10}
	整体	—	7.96×10^{11}	9.53×10^{10}	7.76×10^7	9.72×10^{10}	8.06×10^{11}
参数量	发送端	—	5.25×10^7	9.48×10^6	4.99×10^6	2.25×10^6	5.25×10^7
	接收端	—	1.42×10^7	7.43×10^6	5.51×10^6	1.95×10^5	2.61×10^7
	整体	—	6.67×10^7	1.69×10^7	1.05×10^7	2.44×10^6	7.86×10^7

3.2.5 复杂度分析

为了评估水下语音通信中模型推理的复杂度, 本文使用 NVIDIA GeForce RTX 3090Ti GPU 在相同硬件环境下对多种方法的计算性能进行了评估, 结果如表 7 所示。评估的性能指标包括测试集每条语音的平均处理时间, 浮点运算次数 (FLOPs) 和参数量。从平均处理时间来看, SUNSC 处于中等水平。由于 SUNSC 采用了预训练的声学模型, 并且将语音的内容和音高信息分为两条支路分别处理, SUNSC 的 FLOPs 和参数量略高于其他方法。然而鲁棒性验证表明, 其他方法在低比特率下的抗干扰能力有限, 因为它们没有充分考虑信道扰动的影响。相较而言, SUNSC 在各种信道条件下均取得了最优的重建性能。此外, SUNSC 对每条语音的平均处理时间为 0.52 s, 实际应用中这是可以接受的。相对于 HuBert, 虽然 FLOPs 增加了 1.25%, 参数量增加了 17.82%, 但在 SNR_c = 6 dB 的 NCS 信道条件下, SUNSC 在 STOI 和 CD 方面分别取得了 31.82% 和 16.16% 的性能提升。

4 结论

本文提出了一种在噪声环境下语义引导的水下语音通信 (SUNSC) 系统。考虑到水声信道的狭窄带宽, 引入了内容语义模块和音高语义模块以提取语音中的语义信息, 实现语音极限压缩。由于信源噪声和信道噪声的双重干扰影响重建语音的准确性和可理解性, 引入了语音去噪网络和语义纠错模块, 以

提高系统在噪声环境下的鲁棒性。进一步, 提出的语音重建网络提取全局语义信息, 优化了重建语音的可理解性。实验结果表明, SUNSC 实现了低至 208 sps 的语音压缩, 同时能够有效应对呼吸噪声和气泡噪声的干扰。即使是在信源噪声和信道噪声的双重干扰下, SUNSC 仍然具有良好的鲁棒性和泛化性, 能够适应多种不同的水声信道, 实现高效、鲁棒的带噪语音的传输与重建。

参 考 文 献

- 王南. 蛙人水下通信技术现状与发展趋势. *声学与电子工程*, 2022(4): 62–65
- Anees M. Speech coding techniques and challenges: A comprehensive literature survey. *Multimedia Tools Appl.*, 2024; **83**(10): 29859–29879
- Woodward B, Sari H. Breathing noise elimination in through-water speech communication between divers. *J. Acoust. Soc. Am.*, 2007; **121**(4): EL156–EL160
- Lin C F. UPMC-based underwater voice transmission scheme with LDPC codes. *Appl. Sci.*, 2021; **11**(4): 1818
- Supplee L M, Cohn R P, Collura J S, et al. MELP: The new federal standard at 2400 bps. IEEE International Conference on Acoustics, Speech, and Signal Processing. IEEE, Munich, Germany, 1997: 1591–1594
- Ryan W E. An introduction to LDPC codes. In: Coding and Signal Processing for Recording Systems, CRC Press, 2004
- 王晶, 徐亮, 陈晓娇, 等. 基于神经网络的低码率语音编码技术研究综述. 信号处理, (2024.4.28)[2024.7.16]. <http://kns.cnki.net/kcms/detail/11.2406.TN.20240428.0916.002.html>
- Défossez A, Copet J, Synnaeve G, et al. High fidelity neural audio compression. arXiv preprint: 2210.13438, 2022

- 9 Jiang X, Peng X, Xue H, *et al.* Latent-domain predictive neural speech coding. *IEEE/ACM Trans. Audio Speech Lang. Process.*, 2023; **31**: 2111–2123
- 10 Kim H Y, Yoon J W, Cho W I, *et al.* Neurally optimized decoder for low bitrate speech codec. *IEEE Signal Process. Lett.*, 2021; **29**: 244–248
- 11 Polyak A, Adi Y, Copet J, *et al.* Speech resynthesis from discrete disentangled self-supervised representations. Interspeech 2021, 22nd Annual Conference of the International Speech Communication Association. Brno, Czech Republic, 2021: 3615–3619
- 12 Huang J, Yan Z, Jiang W, *et al.* A two-stage training framework for joint speech compression and enhancement. arXiv preprint: 2309.04132, 2023
- 13 张亦弛, 张平, 魏急波, 等. 面向智能体的语义通信: 架构与范例. *中国科学: 信息科学*, 2022; **52**(5): 907–921
- 14 Han T, Yang Q, Shi Z, *et al.* Semantic-preserved communication system for highly efficient speech transmission. *IEEE J. Sel. Areas Commun.*, 2022; **41**(1): 245–259
- 15 Weng Z, Qin Z. Semantic communication systems for speech transmission. *IEEE J. Sel. Areas Commun.*, 2021; **39**(8): 2434–2444
- 16 Liu J, Yuan F, Xue C, *et al.* An efficient and robust underwater image compression scheme based on autoencoder. *IEEE J. Oceanic Eng.*, 2023; **48**(3): 925–945
- 17 Lu Y X, Ai Y, Ling Z H. Mp-senet: A speech enhancement model with parallel denoising of magnitude and phase spectra. Interspeech 2023, 24th Annual Conference of the International Speech Communication Association. Dublin, Ireland, 2023: 3834–3838
- 18 Tu Q, Yuan F, Yang W, *et al.* An approach for diver passive detection based on the established model of breathing sound emission. *J. Mar. Sci. Eng.*, 2020; **8**(1): 44
- 19 Kasi K, Zahorian S A. Yet another algorithm for pitch tracking. IEEE International Conference on Acoustics, Speech, and Signal Processing, IEEE, Orlando, FL, USA, 2002: 1-361-1-364
- 20 Hsu W N, Bolte B, Tsai Y H H, *et al.* Hubert: Self-supervised speech representation learning by masked prediction of hidden units. *IEEE/ACM Trans. Audio Speech Lang. Process.*, 2021; **29**: 3451–3460
- 21 Kong J, Kim J, Bae J. HiFi-GAN: Generative adversarial networks for efficient and high fidelity speech synthesis. 34th International Conference on Neural Information Processing Systems, NIPS, Vancouver BC, Canada, 2020: 17022–17033
- 22 Ito K, Johnson L. The LJ Speech Dataset. <https://keithito.com/LJ-Speech-Dataset/>
- 23 Jakubczak S, Katabi D. SoftCast: One-size-fits-all wireless video. The ACM SIGCOMM 2010 Conference, ACM, New Delhi, India, 2010: 449–450
- 24 Taal C H, Hendriks R C, Heusdens R, *et al.* An algorithm for intelligibility prediction of time-frequency weighted noisy speech. *IEEE Trans. Audio Speech Lang. Process.*, 2011; **19**(7): 2125–2136
- 25 Kitawaki N, Nagabuchi H, Itoh K. Objective quality evaluation for low-bit-rate speech coding systems. *IEEE J. Sel. Areas Commun.*, 1988; **6**(2): 242–248
- 26 An K, Chen Q, Deng C, *et al.* FunAudioLLM: Voice understanding and generation foundation models for natural interaction between humans and LLMs. arXiv preprint: 2407.04051, 2024
- 27 Zhao H, Ji F, Li Q, *et al.* Federated meta-learning enhanced acoustic radio cooperative framework for ocean of things. *IEEE J. Sel. Topics Signal Process.*, 2022; **16**(3): 474–486
- 28 Yu J, Luo Y. Efficient monaural speech enhancement with universal sample rate band-split RNN. IEEE International Conference on Acoustics, Speech and Signal Processing, IEEE, Rhodes Island, Greece, 2023: 1–5